

Fundamentos em Telecomunicações em Tecnologias Facilitadoras

- Fundamentos de infraestrutura de TI
- Tema principal dessa apresentação: conceitos relacionados à virtualização, com foco em confiabilidade, disponibilidade, regiões, zonas de disponibilidade, agrupamento de recursos, balanceamento de carga e escalabilidade em ambientes de data center e cloud

Conceitos relacionados à virtualização

- Nos módulos anteriores foram apresentados os principais componentes de uma infraestrutura de TI
- Esses componentes incluem servidores, rede, armazenamento, data centers, sistemas operacionais e recursos virtualizados
- Também foi visto que a virtualização é essencial para atender requisitos modernos como flexibilidade, escalabilidade e segurança
- Nesta apresentação, o foco passa a ser outro ponto muito importante: a disponibilidade dos recursos oferecidos às aplicações e a confiabilidade da implementação
- Ou seja, não basta virtualizar recursos
- Também é necessário garantir que esses recursos continuem funcionando mesmo diante de falhas

Por que disponibilidade e confiabilidade são importantes?

- Aplicações modernas precisam estar acessíveis praticamente o tempo todo
- Em empresas, uma aplicação fora do ar pode significar perda de vendas, perda de produtividade e prejuízo financeiro
- Em telecomunicações, uma falha pode afetar milhares ou milhões de usuários
- Por isso, a infraestrutura precisa ser planejada para suportar falhas sem interromper completamente o serviço
- A virtualização ajuda nisso porque permite distribuir, mover, replicar e escalar recursos de forma mais dinâmica

Disponibilidade

- Disponibilidade é a capacidade de um sistema ou serviço estar acessível quando o usuário precisa
- Um serviço disponível é aquele que continua funcionando ou volta rapidamente após uma falha
- Em ambientes de TI e cloud, disponibilidade está muito ligada à continuidade do serviço

- Exemplos:
 - Um site precisa continuar acessível mesmo se um servidor falhar
 - Um serviço de telecomunicações precisa continuar funcionando mesmo se um data center tiver problema
 - Uma aplicação crítica precisa ter cópias ou instâncias em locais diferentes

Confiabilidade

- Confiabilidade é a capacidade de um sistema funcionar corretamente ao longo do tempo
- Está ligada à estabilidade e à previsibilidade da infraestrutura
- Um sistema confiável falha pouco e se comporta de forma esperada
- Em infraestrutura de TI, confiabilidade depende de:
 - Bons equipamentos
 - Redundância
 - Monitoramento
 - Automação
 - Arquitetura bem planejada
 - Testes
 - Recuperação de falhas

Diferença entre disponibilidade e confiabilidade

Conceito	Ideia principal	Exemplo
Disponibilidade	O serviço está acessível quando necessário	Aplicação continua online mesmo com falha em uma instância
Confiabilidade	O sistema funciona corretamente ao longo do tempo	Infraestrutura apresenta poucas falhas e comportamento estável

- Os dois conceitos estão ligados
- Um sistema confiável tende a ter boa disponibilidade
- Mas também é possível aumentar disponibilidade usando redundância, mesmo quando algum componente falha

Resiliência

- Resiliência é a capacidade de resistir a falhas e se recuperar rapidamente
- Em cloud e data centers, resiliência significa que o sistema não depende de um único ponto de falha
- Se um recurso falhar, outro assume

- Se uma zona tiver problema, outra pode manter a aplicação funcionando
- A resiliência é um dos motivos para dividir infraestrutura em regiões e zonas de disponibilidade

Regiões

- Uma região é uma área geográfica onde um provedor de cloud possui infraestrutura
- Cada região normalmente possui vários data centers ou zonas de disponibilidade
- Exemplos de regiões:
 - América do Norte
 - Europa
 - Ásia
 - América do Sul
- A escolha da região influencia:
 - Latência
 - Custo
 - Conformidade legal
 - Localização dos dados
 - Disponibilidade dos serviços
 - Proximidade do usuário final

Zona de disponibilidade

- AZ significa Availability Zone
- Em português, zona de disponibilidade
- Uma zona de disponibilidade é um local isolado dentro de uma região
- Cada AZ possui infraestrutura própria, como energia, rede e refrigeração
- A ideia é que uma falha em uma AZ não afete automaticamente as outras
- Por isso, aplicações críticas podem ser distribuídas em várias AZs
- Isso aumenta disponibilidade e resiliência

Região x zona de disponibilidade

Conceito	O que é	Função principal
Região	Área geográfica maior	Aproximar serviços dos usuários e atender requisitos locais
Zona de disponibilidade	Data center ou grupo isolado dentro de uma região	Reduzir impacto de falhas locais

- Uma região pode ter várias AZs
- Uma aplicação pode usar mais de uma AZ dentro da mesma região
- Em aplicações globais, também pode usar múltiplas regiões

Por que dividir data centers em regiões e AZs?

- A divisão em regiões e zonas de disponibilidade ajuda a aumentar a disponibilidade dos serviços
- Também melhora a confiabilidade e a recuperação em caso de falhas
- Se tudo estivesse concentrado em um único data center, uma falha local poderia derrubar o serviço inteiro
- Com AZs, os recursos podem ser distribuídos
- Assim, se uma zona falhar, outra pode continuar atendendo os usuários

Alta disponibilidade

- Alta disponibilidade é uma estratégia para manter sistemas acessíveis mesmo quando ocorrem falhas
- Para isso, os recursos são duplicados, distribuídos e monitorados
- Em cloud, alta disponibilidade normalmente envolve:
 - Múltiplas instâncias
 - Múltiplas zonas de disponibilidade
 - Balanceadores de carga
 - Replicação de dados
 - Auto scaling
 - Recuperação automática
- O objetivo é reduzir tempo de indisponibilidade

Tolerância a falhas

- Tolerância a falhas é a capacidade de continuar funcionando mesmo quando algum componente falha
- Exemplo:
 - Uma aplicação possui três instâncias em AZs diferentes
 - Uma instância falha
 - O balanceador de carga envia o tráfego para as instâncias restantes
 - O usuário não percebe a falha
- Esse tipo de arquitetura é essencial em ambientes críticos

Recuperação de desastres

- Recuperação de desastres é o conjunto de estratégias para restaurar serviços após uma falha grave
- Uma falha grave pode envolver:
 - Queda de data center
 - Incêndio
 - Falha elétrica
 - Ataque cibernético
 - Erro humano
 - Problema regional
- Para isso, podem ser usados backups, replicação em outra região e planos de contingência
- A recuperação de desastres é uma camada além da alta disponibilidade local

Vantagens da estrutura em região AZ

- A parte interativa da apresentação destaca vantagens da utilização da estrutura em região e AZ
- As principais vantagens são:
 - Resiliência
 - Recuperação de falhas
 - Redução de latência
 - Gerenciamento de custos

Resiliência com AZs

- A resiliência aumenta porque os recursos não ficam concentrados em um único ponto
- Se uma zona de disponibilidade falhar, os serviços podem continuar em outra zona
- Isso reduz o risco de indisponibilidade total
- Em aplicações críticas, distribuir recursos entre AZs é uma prática fundamental

Recuperação de falhas

- A estrutura com AZs facilita recuperação de falhas
- Se um recurso parar de funcionar, outro pode assumir
- Se uma instância cair, uma nova pode ser criada automaticamente
- Se uma zona apresentar problema, o tráfego pode ser redirecionado
- Isso reduz o tempo de recuperação e melhora a continuidade do serviço

Redução de latência

- Latência é o tempo que um dado leva para ir de um ponto a outro

- Ao escolher regiões próximas dos usuários, a latência pode ser reduzida
- Isso melhora a experiência do usuário
- Em telecomunicações, baixa latência é essencial para serviços como:
 - Aplicações em tempo real
 - 5G
 - Jogos online
 - Videoconferência
 - IoT
 - Edge computing

Gerenciamento de custos

- A estrutura em regiões e AZs também ajuda no gerenciamento de custos
- O uso de recursos pode ser ajustado conforme a demanda
- Recursos podem ser escalados para cima ou para baixo
- Também é possível escolher regiões, tipos de instância e modelos de implantação conforme o custo-benefício
- Em cloud, pagar sob demanda torna o planejamento de custos muito importante

Regiões e zonas de disponibilidade na AWS

- AWS significa Amazon Web Services
- É uma das maiores plataformas de cloud pública do mundo
- A apresentação mostra que a AWS possui infraestrutura distribuída ao redor do mundo
- Essa infraestrutura é composta por regiões e zonas de disponibilidade
- Cada região da AWS possui uma ou mais zonas de disponibilidade
- A ideia é permitir que aplicações sejam implantadas de forma resiliente, distribuída e com alta disponibilidade

Exemplo de estrutura possível na AWS

- A apresentação mostra uma estrutura com regiões AWS, AZs, VPCs e sub-redes
- VPC significa Virtual Private Cloud
- Em português, nuvem privada virtual
- Uma VPC é uma rede virtual isolada dentro da cloud
- Dentro da VPC, podem existir sub-redes públicas e privadas
- As sub-redes podem ser distribuídas em diferentes zonas de disponibilidade
- Isso permite separar recursos e melhorar segurança e disponibilidade

VPC

- VPC é uma rede virtual criada dentro de um provedor cloud
- Ela permite organizar recursos como servidores, bancos de dados, aplicações e balanceadores
- Dentro da VPC, é possível definir:
 - Faixas de endereços IP
 - Sub-redes
 - Rotas
 - Regras de segurança
 - Gateways
 - Conectividade com internet ou redes privadas
- A VPC funciona como um ambiente de rede controlado dentro da cloud

Sub-rede pública

- Sub-rede pública é uma sub-rede que pode ter acesso direto à internet, dependendo da configuração
- Normalmente é usada para recursos que precisam receber tráfego externo
- Exemplos:
 - Balanceadores de carga
 - Servidores web
 - Bastion hosts
 - Gateways
- Mesmo sendo pública, ela precisa ter regras de segurança bem configuradas

Sub-rede privada

- Sub-rede privada é uma sub-rede sem exposição direta à internet
- É usada para recursos internos que não devem ser acessados diretamente de fora
- Exemplos:
 - Bancos de dados
 - Servidores internos
 - Aplicações sensíveis
 - Serviços de backend
- Essa separação melhora a segurança
- O usuário externo pode acessar a aplicação por um balanceador em sub-rede pública, enquanto o banco de dados fica protegido em sub-rede privada

Regiões e zonas de disponibilidade na Microsoft Azure

- Microsoft Azure é uma das maiores plataformas de computação em nuvem do mundo
- Assim como a AWS, possui uma infraestrutura global com regiões e zonas de disponibilidade
- Cada região pode ser composta por uma ou mais zonas de disponibilidade
- Essas zonas são conjuntos de data centers independentes
- Elas são projetadas para garantir resiliência e alta disponibilidade dos serviços em nuvem
- A organização em regiões e AZs permite criar aplicações críticas com redundância e latência reduzida

AWS x Microsoft Azure

Conceito	AWS	Microsoft Azure
Região	Local geográfico com infraestrutura AWS	Local geográfico com infraestrutura Azure
Zona de disponibilidade	Data centers isolados dentro da região	Data centers independentes dentro da região
Objetivo	Alta disponibilidade, resiliência e baixa latência	Alta disponibilidade, resiliência e baixa latência
Uso	Distribuir aplicações e recursos	Distribuir aplicações e recursos

- Embora os nomes e detalhes possam variar, a ideia arquitetural é parecida
- Os provedores organizam sua infraestrutura para reduzir impacto de falhas e aproximar serviços dos usuários

Agrupamento de recursos

- Agrupamento de recursos é organizar recursos computacionais em grupos para facilitar gerenciamento, escalabilidade e disponibilidade
- Um grupo pode conter várias instâncias de uma aplicação
- Essas instâncias podem estar distribuídas entre zonas de disponibilidade
- O agrupamento permite tratar vários recursos como uma unidade lógica
- Isso facilita:
 - Escalar aplicações
 - Distribuir tráfego
 - Monitorar recursos
 - Aplicar políticas automáticas
 - Aumentar tolerância a falhas

Escalabilidade

- Escalabilidade é a capacidade de ajustar a quantidade de recursos conforme a demanda
- Se a demanda aumenta, mais recursos podem ser adicionados
- Se a demanda diminui, recursos podem ser reduzidos
- A apresentação destaca que grupos de recursos podem ser escalados
- Isso permite ajustar o número de recursos associados à aplicação sob demanda
- Em cloud, escalabilidade é um dos maiores benefícios

Escalabilidade vertical

- Escalabilidade vertical significa aumentar a capacidade de um recurso existente
- Exemplo:
 - Aumentar CPU de uma máquina
 - Aumentar memória RAM
 - Aumentar tamanho do disco
- É como trocar uma máquina por uma mais forte
- Vantagem:
 - Simples de entender
- Limitação:
 - Existe um limite físico ou financeiro
 - Pode exigir parada do serviço dependendo do caso

Escalabilidade horizontal

- Escalabilidade horizontal significa adicionar mais instâncias para dividir a carga
- Exemplo:
 - Em vez de ter um servidor muito grande, usar vários servidores menores
 - Se a demanda aumenta, novas instâncias são criadas
 - O tráfego é distribuído entre elas
- É muito comum em ambientes cloud
- Funciona muito bem com balanceadores de carga

Escalabilidade automática

- Escalabilidade automática acontece quando o sistema ajusta recursos sozinho com base em políticas
- Exemplo:
 - Se CPU passar de 80%, criar novas instâncias
 - Se tráfego cair, remover instâncias extras

- Se número de requisições aumentar, escalar o grupo
- Isso melhora custo e desempenho
- A aplicação usa mais recursos quando precisa e menos recursos quando a demanda cai

Balanceamento de carga

- Balanceamento de carga é a distribuição do tráfego entre várias instâncias ou recursos
- O objetivo é evitar que uma única instância fique sobrecarregada
- Um balanceador de carga recebe as requisições e distribui entre servidores disponíveis
- Isso melhora:
 - Desempenho
 - Disponibilidade
 - Tolerância a falhas
 - Experiência do usuário

Como funciona o balanceamento de carga?

- O usuário envia uma requisição para acessar a aplicação
- A requisição chega ao balanceador de carga
- O balanceador verifica quais instâncias estão disponíveis
- Ele encaminha a requisição para uma instância saudável
- Se uma instância falhar, o balanceador deixa de enviar tráfego para ela
- Assim, o serviço continua funcionando com as instâncias restantes

Balanceamento de carga e tolerância a falhas

- O balanceamento de carga aumenta tolerância a falhas porque evita dependência de uma única instância
- Se uma instância sair do ar, as outras continuam atendendo
- Em arquiteturas distribuídas entre AZs, o balanceador pode enviar tráfego para instâncias em zonas diferentes
- Isso reduz o impacto de falhas locais

Relação entre escalabilidade e balanceamento de carga

- Escalabilidade e balanceamento de carga trabalham juntos
- A escalabilidade cria ou remove instâncias conforme demanda
- O balanceador distribui o tráfego entre essas instâncias
- Exemplo:
 - A aplicação começa com duas instâncias

- A demanda aumenta
- O sistema cria mais duas instâncias
- O balanceador passa a distribuir tráfego entre quatro instâncias
- Isso melhora desempenho e evita sobrecarga

Arquitetura resiliente em cloud

- Uma arquitetura resiliente combina vários conceitos
- Elementos importantes:
 - Regiões
 - Zonas de disponibilidade
 - VPC
 - Sub-redes públicas e privadas
 - Balanceadores de carga
 - Auto scaling
 - Replicação
 - Monitoramento
 - Backup
 - Recuperação de desastres
- O objetivo é manter o serviço funcionando mesmo quando algum componente falha

Exemplo prático de arquitetura

- Uma aplicação web pode ser implantada assim:
 - Balanceador de carga em sub-rede pública
 - Servidores de aplicação em sub-redes privadas
 - Instâncias distribuídas em duas ou mais AZs
 - Banco de dados replicado
 - Políticas de auto scaling
 - Monitoramento de saúde das instâncias
- Se uma instância falhar, o balanceador redireciona o tráfego
- Se a demanda aumentar, o auto scaling cria novas instâncias
- Se uma AZ falhar, a outra continua operando

Relação com virtualização

- Esses conceitos se relacionam diretamente com virtualização porque dependem de recursos lógicos e flexíveis

- Instâncias, redes virtuais, sub-redes, grupos de recursos e balanceadores são gerenciados de forma lógica
- Isso permite provisionar, mover, escalar e proteger aplicações com mais agilidade
- Sem virtualização, seria muito mais difícil criar esse tipo de arquitetura distribuída e elástica

Relação com telecomunicações

- Em telecomunicações, alta disponibilidade e baixa latência são requisitos críticos
- Redes 5G, funções virtualizadas e serviços digitais dependem de infraestrutura confiável
- Data centers distribuídos e zonas de disponibilidade ajudam a manter serviços próximos dos usuários e resistentes a falhas
- Isso é importante para:
 - Núcleo 5G
 - Edge computing
 - Serviços críticos
 - IoT
 - Aplicações empresariais
 - Redes privadas
 - Funções de rede virtualizadas

Edge computing

- Edge computing significa levar processamento para mais perto do usuário ou do dispositivo
- Isso reduz latência e melhora desempenho
- Em telecomunicações, edge computing é importante porque muitos serviços exigem resposta rápida
- Exemplos:
 - Veículos conectados
 - Indústria 4.0
 - Realidade aumentada
 - Monitoramento em tempo real
 - Aplicações 5G
- A organização em regiões, zonas e data centers distribuídos ajuda a viabilizar esse modelo

Boas práticas para disponibilidade

- Distribuir recursos em múltiplas AZs
- Usar balanceadores de carga
- Configurar auto scaling

- Separar sub-redes públicas e privadas
- Monitorar a saúde das instâncias
- Fazer backup regularmente
- Replicar dados críticos
- Planejar recuperação de desastres
- Evitar ponto único de falha
- Testar cenários de falha

Ponto único de falha

- Ponto único de falha é um componente que, se parar, derruba todo o serviço
- Exemplo:
 - Uma aplicação com apenas um servidor
 - Um banco de dados sem réplica
 - Um único link de rede
 - Um único data center
- Arquiteturas modernas tentam eliminar ou reduzir pontos únicos de falha
- Para isso, usam redundância, distribuição geográfica e balanceamento

Resumo

- Virtualização:
 - Permite flexibilidade, escalabilidade e segurança
 - Também ajuda na disponibilidade e confiabilidade dos serviços
- Disponibilidade:
 - Garante que o serviço esteja acessível quando necessário
- Confiabilidade:
 - Garante funcionamento estável e correto ao longo do tempo
- Resiliência:
 - Capacidade de resistir e se recuperar de falhas
- Região:
 - Local geográfico onde existe infraestrutura cloud
- AZ:
 - Zona de disponibilidade isolada dentro de uma região
 - Ajuda a reduzir impacto de falhas locais
- AWS e Azure:
 - Usam regiões e zonas de disponibilidade para oferecer alta disponibilidade e resiliência
- VPC:

- Rede virtual isolada dentro da cloud
- Sub-rede pública:
 - Pode expor recursos para acesso externo, quando configurada para isso
- Sub-rede privada:
 - Protege recursos internos sem exposição direta à internet
- Escalabilidade:
 - Ajusta recursos conforme a demanda
- Auto scaling:
 - Escala recursos automaticamente com base em políticas
- Balanceamento de carga:
 - Distribui tráfego entre instâncias
 - Evita sobrecarga e aumenta tolerância a falhas

Qual é o principal objetivo de uma região no contexto de infraestrutura de Data Centers?

- ☐ Concentrar os recursos em um único Data Center para aumentar a eficiência.
- ☐ Otimizar a capacidade de processamento de dados em uma única localização.
- ☒ Isolar falhas e desastres regionais, distribuindo e replicando dados.
- ☐ Garantir a redução de custos operacionais em uma área específica.

Qual é o principal objetivo de uma Zona de Disponibilidade (AZ)?

- ☐ Reduzir o custo de infraestrutura ao concentrar os serviços em uma única AZ.
- ☒ Fornecer redundância e tolerância a falhas dentro de uma mesma região.
- ☐ Centralizar os recursos em uma única região para melhorar a eficiência de dados.
- ☐ Aumentar a capacidade de processamento de dados em uma única zona.

Quais são as principais vantagens da utilização da estrutura em Região e Zona de Disponibilidade (AZ)?

- ☒ Melhoria de resiliência, recuperação, latência e gerenciamento de custos.
- ☐ Centralização dos recursos em uma única localização para facilitar a gestão.
- ☐ Maximização do processamento de dados em uma única AZ para reduzir custos.
- ☐ Aumento de eficiência energética e redução de consumo.

Quais são dois conceitos fundamentais para gerenciar a disponibilidade e o atendimento às demandas do usuário em uma infraestrutura de TI virtualizada?

- ☐ Armazenamento distribuído e gerenciamento manual de recursos.
- ☒ Balanceamento de Carga e Escalabilidade.
- ☐ Centralização de serviços e redução de capacidade de resposta.
- ☐ Redundância de dados e alocação fixa de recursos.