

Fundamentos em telecomunicações em tecnologias facilitadoras

- Fundamentos de IA
- Tema principal dessa apresentação: conceitos sobre aprendizado de máquina, definição de machine learning, etapas básicas para criação de modelos, itens essenciais para o aprendizado, tipos de sistemas de aprendizado de máquina e principais técnicas como regressão, classificação, redução de dimensionalidade, agrupamento e reforço

Introdução ao aprendizado de máquina

- Aprendizado de máquina também é chamado de Machine Learning
- A sigla mais usada é ML
- Machine Learning é um campo dentro da Inteligência Artificial
- A ideia principal é permitir que computadores aprendam a partir de dados
- Em vez de programar todas as regras manualmente, o sistema observa exemplos, identifica padrões e melhora seu desempenho em uma tarefa
- Esse processo é importante porque muitos problemas reais são difíceis de resolver apenas com regras fixas
- Em situações com muitos dados, muitas variáveis e padrões complexos, o aprendizado de máquina consegue encontrar relações que seriam difíceis de escrever manualmente

Definição de aprendizado de máquina

- O aprendizado de máquina é o processo pelo qual uma máquina aprende e extrai conhecimento sobre algum contexto a partir de dados
- Esse aprendizado acontece sem que exista uma regra de associação previamente definida
- Isso significa que o sistema não recebe todas as respostas prontas em forma de regras
- Ele recebe dados e tenta aprender os padrões existentes nesses dados
- A apresentação compara o processo artificial ao processo biológico de aprendizado do cérebro humano
- A inspiração para desenvolver aprendizado de máquina veio justamente da observação do comportamento humano
- Assim como pessoas aprendem observando exemplos, errando, corrigindo e reconhecendo padrões, um modelo de ML aprende a partir de dados e ajustes

Ideia principal da definição

- A máquina aprende a partir de dados
- Ela extrai conhecimento de um contexto

- Ela não depende de regras previamente escritas para cada situação
- Ela identifica padrões
- Depois usa esses padrões para fazer previsões, classificações ou decisões
- Exemplo intuitivo:
 - Em vez de programar regra por regra para identificar spam
 - O sistema recebe vários e-mails marcados como spam e não spam
 - Ele aprende padrões comuns em e-mails de spam
 - Depois consegue classificar novos e-mails

Por que usar aprendizado de máquina?

- O aprendizado de máquina é usado porque permite lidar com problemas em que os padrões existem, mas não são fáceis de descrever manualmente
- Também é útil quando o ambiente muda com o tempo
- Um sistema tradicional depende de regras fixas
- Um sistema de ML pode ser treinado novamente com dados mais recentes
- Isso permite adaptação a novos cenários
- Exemplos:
 - Detectar fraudes bancárias
 - Prever demanda de tráfego em redes
 - Classificar imagens
 - Recomendar filmes ou produtos
 - Diagnosticar falhas em equipamentos
 - Prever consumo de energia
 - Identificar padrões de comportamento de usuários

Diferença entre programação tradicional e aprendizado de máquina

Abordagem	Como funciona	Exemplo
Programação tradicional	O programador cria regras explícitas	Se a mensagem tem palavra suspeita, marcar como spam
Aprendizado de máquina	O modelo aprende padrões a partir de dados	O modelo analisa e-mails anteriores e aprende quais padrões indicam spam

- Na programação tradicional, o conhecimento está nas regras escritas pelo programador
- No aprendizado de máquina, o conhecimento é extraído dos dados
- Isso não elimina o programador

- O programador continua importante para escolher dados, preparar o problema, selecionar algoritmos, avaliar resultados e implementar o sistema

Aprendizado artificial e aprendizado biológico

- A apresentação relaciona o processo artificial de ML com o aprendizado biológico do cérebro
- Essa comparação ajuda a entender a lógica do aprendizado
- Um ser humano aprende observando exemplos e ajustando sua compreensão
- Uma máquina aprende analisando dados e ajustando seus parâmetros
- Em ambos os casos, existe uma tentativa de reconhecer padrões e usar esses padrões em novas situações
- Porém, a máquina não aprende exatamente como uma pessoa
- Ela usa modelos matemáticos e algoritmos para ajustar seu comportamento

Contribuições históricas para o aprendizado de máquina

- A parte interativa da apresentação cita Alan Turing e Arthur Samuel como referências importantes
- Esses nomes ajudam a entender a origem conceitual do aprendizado de máquina
- Alan Turing foi importante por discutir se máquinas poderiam apresentar comportamento inteligente
- Arthur Samuel é muito associado à definição clássica de aprendizado de máquina como a área que dá aos computadores a capacidade de aprender sem serem explicitamente programados
- Essas contribuições ajudaram a formalizar a área e tornaram o aprendizado de máquina um campo mais claro dentro da IA

Alan Turing

- Alan Turing foi um dos nomes mais importantes da computação e da Inteligência Artificial
- Ele propôs o Teste de Turing, que avalia se uma máquina consegue apresentar comportamento semelhante ao humano em uma conversa
- Embora o Teste de Turing esteja mais ligado à IA em geral, ele influenciou a discussão sobre máquinas inteligentes
- A ideia principal é observar o comportamento da máquina
- Se a máquina consegue agir de forma inteligente em uma tarefa, ela pode ser analisada como sistema inteligente

Arthur Samuel

- Arthur Samuel foi um dos primeiros pesquisadores a trabalhar diretamente com a ideia de aprendizado de máquina
- Ele desenvolveu sistemas que aprendiam a jogar damas
- A contribuição dele foi importante porque mostrou que máquinas poderiam melhorar seu desempenho com experiência
- Isso é uma ideia central em ML:
 - O sistema executa uma tarefa
 - Recebe dados ou experiência
 - Ajusta seu comportamento
 - Melhora seu resultado ao longo do tempo

O que é aprendizado de máquina na prática?

- Na prática, aprendizado de máquina é um processo de construção de modelos
- Um modelo é uma representação matemática treinada com dados
- Esse modelo aprende relações entre entradas e saídas ou encontra padrões internos nos dados
- Depois do treinamento, ele pode ser usado para analisar novos casos
- Exemplo:
 - Entrada: idade, renda, histórico de compras
 - Modelo aprende padrões de consumo
 - Saída: probabilidade de o cliente comprar um produto

Modelo de aprendizado de máquina

- Um modelo de ML é o resultado do treinamento de um algoritmo com dados
- O algoritmo é o método usado para aprender
- O modelo é o que foi aprendido
- Exemplo:
 - Algoritmo: árvore de decisão
 - Dados: histórico de clientes
 - Modelo treinado: árvore com regras aprendidas a partir dos dados
- Depois de treinado, o modelo pode fazer previsões ou classificações em dados novos

Etapas básicas para criar um modelo de aprendizado de máquina

- A parte interativa da apresentação indica que existem passos básicos para criar um modelo de ML
- Um fluxo geral pode ser entendido assim:
 - Definir o problema

- Coletar dados
- Preparar os dados
- Escolher o tipo de aprendizado
- Selecionar o algoritmo
- Treinar o modelo
- Validar e testar o modelo
- Ajustar o modelo
- Usar o modelo em novos dados

Definir o problema

- Antes de aplicar ML, é preciso saber qual problema será resolvido
- A pergunta precisa estar clara
- Exemplos:
 - Quero prever um valor?
 - Quero classificar uma categoria?
 - Quero descobrir grupos escondidos?
 - Quero reduzir a quantidade de variáveis?
 - Quero que um agente aprenda por tentativa e erro?
- Essa definição orienta a escolha do tipo de algoritmo

Coletar dados

- Dados são a base do aprendizado de máquina
- Sem dados, o modelo não tem de onde aprender
- Os dados podem vir de várias fontes:
 - Sensores
 - Sistemas corporativos
 - Planilhas
 - Bancos de dados
 - Redes sociais
 - Imagens
 - Logs de rede
 - Dispositivos IoT
 - Experimentos
- A qualidade dos dados influencia diretamente a qualidade do modelo

Preparar os dados

- Preparar dados é uma das etapas mais importantes
- Dados reais normalmente vêm com problemas
- Podem existir valores faltantes, ruídos, duplicações, erros e formatos inconsistentes
- O preparo pode incluir:
 - Limpeza dos dados
 - Remoção de duplicatas
 - Tratamento de valores ausentes
 - Normalização
 - Codificação de variáveis categóricas
 - Separação entre treino e teste
 - Seleção de características importantes
- Um modelo treinado com dados ruins tende a gerar resultados ruins

Escolher o tipo de aprendizado

- O tipo de aprendizado depende do problema e dos dados disponíveis
- Se existem dados rotulados, o problema pode ser supervisionado
- Se os dados não possuem rótulos, pode ser não supervisionado
- Se existe um agente aprendendo por recompensa, pode ser aprendizado por reforço
- Essa escolha é essencial porque define o caminho da modelagem

Treinar o modelo

- Treinar o modelo significa apresentar dados ao algoritmo para que ele aprenda padrões
- Durante o treinamento, o modelo ajusta seus parâmetros internos
- O objetivo é reduzir erros e melhorar desempenho
- Em problemas supervisionados, o modelo compara a previsão com a resposta correta
- Em problemas não supervisionados, ele tenta encontrar padrões ou estruturas nos dados

Validar e testar o modelo

- Validar e testar o modelo é necessário para saber se ele aprendeu de verdade
- O modelo não deve apenas decorar os dados de treinamento
- Ele precisa funcionar bem em dados novos
- Por isso, normalmente os dados são divididos em:
 - Conjunto de treino
 - Conjunto de validação
 - Conjunto de teste
- O teste final ajuda a estimar o desempenho do modelo em situações reais

O que é essencial para o aprendizado de máquina?

- A apresentação destaca que três itens são essenciais para que o aprendizado de máquina aconteça
- Primeiro, precisa existir um padrão nos dados que possa ser identificado e aprendido
- Segundo, precisa haver um relacionamento matemático ou modelável entre os dados
- Terceiro, precisa haver dados suficientes para o treinamento
- Mesmo um problema simples para um humano precisa de dados para que o padrão seja reconhecido e aprendido por uma máquina

Padrão nos dados

- Um modelo de ML só consegue aprender se existir algum padrão nos dados
- Se os dados forem totalmente aleatórios, o modelo não consegue encontrar uma relação útil
- Exemplo:
 - Se clientes com determinado comportamento compram mais um produto, existe um padrão
 - Se a temperatura e a vibração de uma máquina mudam antes de uma falha, existe um padrão
 - Se imagens de gatos possuem formas e texturas semelhantes, existe um padrão visual

Relacionamento matemático

- O aprendizado de máquina depende de relações matemáticas
- Essas relações podem ser simples ou complexas
- Em uma regressão linear, a relação pode ser aproximada por uma reta
- Em uma rede neural, a relação pode ser muito mais complexa
- O importante é que o modelo consiga representar a relação entre os dados de entrada e o resultado esperado ou entre padrões internos dos dados

Dados suficientes para treinamento

- Dados suficientes são necessários para que o modelo aprenda com qualidade
- Poucos dados podem gerar um modelo fraco ou pouco confiável
- Dados com baixa qualidade também prejudicam o aprendizado
- O ideal é que os dados representem bem o problema real
- Exemplo:

- Para treinar um modelo de diagnóstico, os dados precisam representar diferentes pacientes, condições e resultados
- Para prever tráfego em rede, os dados precisam representar diferentes horários, cargas e situações

Tipos de sistemas de aprendizado de máquina

- A apresentação organiza os sistemas de aprendizado de máquina em alguns grupos principais
- O mapa apresentado mostra:
 - Aprendizado supervisionado
 - Aprendizado não supervisionado
 - Aprendizado por reforço
- Dentro do aprendizado supervisionado aparecem:
 - Classificação
 - Regressão
- Dentro do aprendizado não supervisionado aparecem:
 - Redução de dimensionalidade
 - Agrupamento

Mapa geral dos tipos de ML

Tipo de aprendizado	Ideia principal	Técnicas associadas
Supervisionado	Aprende com dados rotulados	Regressão e classificação
Não supervisionado	Descobre padrões sem rótulos	Agrupamento e redução de dimensionalidade
Por reforço	Aprende por tentativa, erro e recompensa	Agentes, ações e recompensas

Aprendizado supervisionado

- Aprendizado supervisionado é quando o modelo aprende a partir de dados rotulados
- Dados rotulados são dados que já possuem a resposta correta
- Exemplo:
 - Entrada: características de uma casa
 - Rótulo: preço da casa
 - Entrada: imagem de animal

- Rótulo: gato ou cachorro
- O objetivo do modelo é aprender a relação entre entrada e saída
- Depois, ele usa essa relação para prever a saída de novos exemplos

Regressão

- Regressão é uma técnica de aprendizado supervisionado usada para prever valores contínuos
- Valor contínuo é uma quantidade numérica
- Diferente da classificação, que prevê categorias, a regressão prevê números
- Exemplos:
 - Prever preço de uma casa
 - Prever temperatura
 - Prever consumo de energia
 - Prever tráfego de rede
 - Prever tempo de vida útil de um equipamento

Objetivos da regressão

- A regressão possui dois objetivos principais
- Primeiro, prever ou estimar o valor de uma variável de saída com base em uma ou mais variáveis de entrada
- Segundo, modelar e compreender a relação entre as variáveis de entrada e a variável de saída
- Isso significa que a regressão pode ser usada tanto para previsão quanto para interpretação da relação entre variáveis

Variável de entrada e variável de saída

- Variáveis de entrada são as informações usadas pelo modelo para aprender
- Variável de saída é o resultado que o modelo tenta prever
- Exemplo:
 - Entradas: tamanho da casa, localização e número de quartos
 - Saída: preço da casa
- O modelo tenta aprender como as entradas influenciam a saída

Algoritmos de regressão

- A apresentação cita alguns algoritmos importantes:
 - Regressão linear

- Regressão polinomial
- Regressão logística
- Redes neurais para regressão

Regressão linear

- Regressão linear estima uma relação linear entre a variável dependente e uma ou mais variáveis independentes
- Relação linear significa que o modelo tenta ajustar uma reta ou um hiperplano aos dados
- É uma técnica simples, interpretável e muito usada como ponto de partida
- Exemplo:
 - Quanto maior o tamanho de uma casa, maior tende a ser o preço

Regressão polinomial

- Regressão polinomial é uma extensão da regressão linear
- Ela permite modelar relações não lineares
- Isso é útil quando os dados não seguem uma reta simples
- Exemplo:
 - O desempenho de um sistema pode crescer até certo ponto e depois estabilizar
 - Essa relação pode ser melhor representada por uma curva

Regressão logística

- A apresentação cita regressão logística dentro dos algoritmos de regressão, mas destaca que ela é usada para classificação
- A regressão logística modela a probabilidade de uma categoria binária
- Categoria binária significa duas classes possíveis
- Exemplos:
 - Fraude ou não fraude
 - Doente ou saudável
 - Spam ou não spam
- Apesar do nome regressão, seu uso mais comum é classificação

Redes neurais para regressão

- Redes neurais podem ser usadas para regressão quando a relação entre os dados é complexa
- Elas usam camadas ocultas e funções não lineares para aprender padrões difíceis

- São úteis quando modelos simples não conseguem representar bem o comportamento dos dados
- Exemplo:
 - Previsão de demanda com muitas variáveis
 - Previsão de falhas com sinais de sensores
 - Modelagem de séries temporais

Classificação

- Classificação é uma técnica usada para prever a categoria ou classe de uma nova observação
- Diferente da regressão, que prevê valores contínuos, a classificação prevê categorias discretas e rotuladas
- Exemplos:
 - E-mail é spam ou não spam
 - Imagem contém gato ou cachorro
 - Cliente vai comprar ou não comprar
 - Transação é fraudulenta ou legítima
 - Paciente pertence a um grupo de risco ou não

Objetivos da classificação

- A classificação busca atribuir um rótulo de classe a uma observação com base em suas características
- Também busca detectar padrões e tendências nos dados
- Esses padrões podem ser usados para categorizar novas observações
- Exemplo:
 - Um modelo aprende características de transações fraudulentas
 - Depois classifica novas transações como suspeitas ou normais

Diferença entre regressão e classificação

Técnica	Saída prevista	Exemplo
Regressão	Valor numérico contínuo	Prever preço, temperatura ou consumo
Classificação	Categoria discreta	Prever spam/não spam ou aprovado/reprovado

- A diferença principal está no tipo de saída
- Se a saída é número contínuo, é regressão

- Se a saída é classe ou categoria, é classificação

Algoritmos de classificação

- A apresentação cita alguns algoritmos importantes:
 - Regressão logística
 - Máquinas de Vetores de Suporte
 - Árvores de decisão
 - k-Nearest Neighbors
 - Redes neurais e Deep Learning

Regressão logística para classificação

- A regressão logística é muito usada para classificação binária
- Ela calcula a probabilidade de uma observação pertencer a uma classe
- Exemplo:
 - Probabilidade de uma transação ser fraude
 - Probabilidade de um paciente ter determinada condição
- A partir dessa probabilidade, o modelo decide a classe

Máquinas de Vetores de Suporte

- Máquinas de Vetores de Suporte também são chamadas de SVM
- SVM significa Support Vector Machine
- O objetivo é encontrar o hiperplano que melhor separa as classes no espaço de características
- Hiperplano é uma fronteira de separação entre classes
- Em duas dimensões, pode ser uma linha
- Em três dimensões, pode ser um plano
- Em dimensões maiores, é chamado de hiperplano

Árvores de decisão

- Árvores de decisão são modelos baseados em regras
- Elas dividem os dados em subconjuntos usando perguntas ou condições simples
- Exemplo:
 - A idade é maior que 30?
 - A renda é maior que determinado valor?
 - O usuário clicou no anúncio?
- Cada divisão aproxima o modelo de uma decisão final

- São modelos fáceis de interpretar

k-Nearest Neighbors

- k-Nearest Neighbors também é chamado de k-NN
- A ideia é classificar uma nova observação com base nos k vizinhos mais próximos
- Se os vizinhos mais próximos pertencem a uma classe, a nova observação tende a receber essa classe
- Exemplo:
 - Uma nova amostra está cercada por exemplos da classe A
 - O modelo classifica essa amostra como classe A

Redes neurais e Deep Learning na classificação

- Redes neurais e Deep Learning são usados em problemas de classificação mais complexos
- Eles utilizam múltiplas camadas para aprender representações profundas dos dados
- São muito usados em:
 - Reconhecimento de imagens
 - Processamento de linguagem natural
 - Reconhecimento de fala
 - Diagnóstico por imagem
 - Detecção de objetos

Aprendizado não supervisionado

- Aprendizado não supervisionado é quando o modelo trabalha com dados sem rótulos
- Isso significa que não existe uma resposta correta previamente indicada
- O objetivo é descobrir padrões, estruturas ou relações escondidas nos dados
- Exemplos:
 - Agrupar clientes com comportamentos parecidos
 - Reduzir variáveis de um conjunto de dados
 - Encontrar padrões em imagens
 - Detectar anomalias

Redução de dimensionalidade

- Redução de dimensionalidade é uma técnica que transforma dados de alta dimensionalidade em um espaço de menor dimensionalidade
- Alta dimensionalidade significa que os dados possuem muitas características ou variáveis

- O objetivo é reduzir a quantidade de variáveis preservando o máximo de informação possível
- Isso pode facilitar visualização, processamento e modelagem
- Exemplo:
 - Uma imagem pode ter milhares de pixels
 - A redução de dimensionalidade tenta representar essa imagem com menos características importantes

Por que reduzir dimensionalidade?

- Dados com muitas variáveis podem ser difíceis de visualizar e processar
- Também podem aumentar o custo computacional
- Algumas variáveis podem ser redundantes ou pouco informativas
- Reduzir dimensionalidade ajuda a:
 - Simplificar o conjunto de dados
 - Melhorar visualização
 - Reduzir ruído
 - Acelerar processamento
 - Evitar modelos muito complexos
 - Facilitar interpretação

Algoritmos de redução de dimensionalidade

- A apresentação cita três algoritmos:
 - PCA
 - LDA
 - Autoencoders

PCA

- PCA significa Principal Component Analysis
- Em português, Análise de Componentes Principais
- O PCA transforma os dados em um novo conjunto de variáveis não correlacionadas
- Essas variáveis são chamadas de componentes principais
- Os componentes são ordenados pela quantidade de variação que explicam nos dados originais
- Em termos simples, o PCA tenta manter as informações mais importantes usando menos variáveis

LDA

- LDA significa Linear Discriminant Analysis
- Em português, Análise Discriminante Linear
- A apresentação mostra que o LDA é similar ao PCA
- Porém, ele também considera a separabilidade das classes
- Isso significa que, além de reduzir a dimensionalidade, ele tenta preservar informações úteis para separar grupos ou classes
- É útil quando existem rótulos e o objetivo é melhorar a distinção entre classes

Autoencoders

- Autoencoders são redes neurais usadas para aprender uma representação comprimida dos dados
- Eles possuem uma parte que codifica os dados em uma forma menor e outra parte que tenta reconstruir os dados originais
- Se o modelo consegue reconstruir bem, significa que a representação reduzida manteve informações importantes
- Autoencoders são úteis para compressão, redução de dimensionalidade, detecção de anomalias e extração de características

Agrupamento

- Agrupamento também é chamado de clustering
- O objetivo é agrupar dados em subconjuntos chamados clusters
- Dentro de um cluster, os itens são mais semelhantes entre si
- Itens de clusters diferentes tendem a ser menos semelhantes
- O agrupamento é uma técnica não supervisionada porque os grupos não são conhecidos antes
- O modelo tenta descobrir esses grupos automaticamente

Exemplo de agrupamento

- Um exemplo citado é segmentar clientes com base em comportamento de compra
- A empresa pode descobrir grupos como:
 - Clientes que compram com frequência
 - Clientes sensíveis a promoções
 - Clientes que compram produtos premium
 - Clientes com risco de abandonar o serviço
- Depois, esses grupos podem ser usados para marketing direcionado ou estratégias diferentes

Algoritmos de agrupamento

- A apresentação cita três algoritmos:
 - k-Means
 - Hierarchical Clustering
 - Gaussian Mixture Models

k-Means

- k-Means particiona os dados em k clusters
- Cada dado pertence ao cluster com o centroide mais próximo
- Centroide é o ponto central de um cluster
- O algoritmo tenta organizar os dados de forma que os elementos dentro de cada grupo sejam parecidos
- É muito usado por ser simples e eficiente

Hierarchical Clustering

- Hierarchical Clustering cria uma árvore de clusters
- Essa árvore mostra relações hierárquicas entre grupos
- Pode funcionar de duas formas:
 - Aglomerativo, também chamado bottom-up
 - Divisivo, também chamado top-down
- No método aglomerativo, cada ponto começa como um cluster e os grupos vão sendo unidos
- No método divisivo, todos começam em um grande grupo e vão sendo separados

Gaussian Mixture Models

- Gaussian Mixture Models também é chamado de GMM
- O GMM assume que os dados são uma mistura de várias distribuições gaussianas
- Distribuição gaussiana é a distribuição normal, com formato de sino
- O objetivo é encontrar a melhor combinação de distribuições que descreve os dados
- Diferente do k-Means, o GMM pode trabalhar com agrupamentos mais flexíveis e probabilísticos

Aprendizado por reforço

- Aprendizado por reforço é um tipo de aprendizado em que um agente aprende a tomar decisões por tentativa e erro
- O agente interage com um ambiente

- Ele executa ações
- Recebe recompensas ou punições
- Com o tempo, aprende quais ações aumentam a recompensa acumulada
- A apresentação cita o aprendizado por reforço dentro dos principais tipos de ML

Agente, ambiente e recompensa

- Agente é quem toma decisões
- Ambiente é o espaço onde o agente atua
- Ação é o que o agente faz
- Recompensa é o retorno recebido após a ação
- Exemplo:
 - Um robô é o agente
 - O ambiente é uma sala
 - A ação é andar para frente
 - A recompensa pode ser positiva se ele se aproxima do objetivo

Exemplos de aprendizado por reforço

- Jogos
- Robótica
- Veículos autônomos
- Controle de tráfego
- Otimização de redes
- Sistemas de recomendação com feedback
- Alocação dinâmica de recursos
- Em telecomunicações, pode ser usado para otimizar decisões em ambientes que mudam continuamente

Comparação entre supervisionado, não supervisionado e reforço

Tipo	Dados usados	Objetivo	Exemplo
Supervisionado	Dados com rótulos	Prever saída correta	Classificação de e-mails e previsão de preço
Não supervisionado	Dados sem rótulos	Descobrir padrões	Agrupamento de clientes
Reforço	Interação com ambiente	Maximizar recompensas	Robô aprendendo a se mover

Aplicações de ML em telecomunicações

- Embora a apresentação seja de fundamentos de IA, o aprendizado de máquina se conecta diretamente com telecomunicações
- Redes modernas geram muitos dados e precisam de automação
- ML pode ser usado para:
 - Prever tráfego de rede
 - Detectar falhas
 - Identificar anomalias
 - Otimizar uso de recursos
 - Melhorar segurança
 - Prever demanda
 - Automatizar operação de redes
 - Melhorar qualidade de serviço
 - Apoiar redes 5G e futuras redes 6G

Dados de qualidade

- A conclusão da apresentação destaca que dados de qualidade são pontos cruciais para ML
- Dados ruins podem prejudicar o modelo
- Problemas comuns:
 - Dados incompletos
 - Dados desbalanceados
 - Dados com ruído
 - Dados duplicados
 - Dados inconsistentes
 - Dados que não representam o problema real
- Por isso, uma parte importante do ML é preparar e validar os dados antes do treinamento

Algoritmos eficientes

- Outro ponto importante é escolher algoritmos adequados
- Não existe um algoritmo melhor para todos os problemas
- A escolha depende de:
 - Tipo de dado
 - Tamanho da base
 - Objetivo do problema
 - Necessidade de interpretação
 - Custo computacional

- Desempenho esperado
- Regressão linear pode ser suficiente para relações simples
- Redes neurais podem ser úteis para relações complexas
- k-Means pode ser adequado para agrupamento

Poder computacional

- O poder computacional também é essencial para o avanço do aprendizado de máquina
- Modelos mais complexos exigem mais processamento
- Deep Learning, por exemplo, depende muito de processamento em larga escala
- Com mais poder computacional, é possível treinar modelos maiores, usar mais dados e resolver problemas mais complexos
- Isso ajuda a explicar por que o ML cresceu tanto nos últimos anos

Métodos de validação

- Métodos de validação são usados para verificar se o modelo funciona bem
- Eles ajudam a evitar que o modelo apenas decore os dados de treino
- Um modelo precisa generalizar
- Generalizar significa funcionar bem em dados novos
- Técnicas comuns:
 - Divisão treino e teste
 - Validação cruzada
 - Métricas de desempenho
 - Avaliação com dados reais

Métricas de desempenho

- Métricas são formas de medir o resultado de um modelo
- Em regressão, podem ser usadas métricas como erro médio ou erro quadrático
- Em classificação, podem ser usadas métricas como acurácia, precisão, recall e F1-score
- A escolha da métrica depende do problema
- Exemplo:
 - Em detecção de fraude, pode ser mais importante identificar fraudes corretamente do que apenas ter alta acurácia geral

Resumo

- Aprendizado de máquina:
 - Campo da IA que permite que computadores aprendam a partir de dados

- Melhora desempenho em tarefas específicas sem regras explícitas para cada caso
- Definição:
 - A máquina aprende e extrai conhecimento a partir de dados
 - Sem uma regra de associação previamente definida
- Itens essenciais:
 - Existência de padrões nos dados
 - Relações matemáticas que possam ser modeladas
 - Dados suficientes para treinamento
- Etapas básicas:
 - Definir problema
 - Coletar dados
 - Preparar dados
 - Escolher algoritmo
 - Treinar modelo
 - Validar e testar
 - Usar o modelo em novos dados
- Aprendizado supervisionado:
 - Usa dados rotulados
 - Inclui regressão e classificação
- Regressão:
 - Previsão de valores contínuos
 - Exemplo: preço, temperatura, consumo ou tráfego
 - Algoritmos: regressão linear, regressão polinomial, regressão logística e redes neurais para regressão
- Classificação:
 - Previsão de categorias discretas
 - Exemplo: spam ou não spam, fraude ou não fraude
 - Algoritmos: regressão logística, SVM, árvores de decisão, k-NN e redes neurais
- Aprendizado não supervisionado:
 - Usa dados sem rótulos
 - Busca descobrir padrões escondidos
- Redução de dimensionalidade:
 - Reduz o número de variáveis preservando informação
 - Algoritmos: PCA, LDA e autoencoders
- Agrupamento:
 - Agrupa dados semelhantes em clusters
 - Algoritmos: k-Means, Hierarchical Clustering e GMM

- Aprendizado por reforço:
 - Um agente aprende por tentativa, erro e recompensa
 - Busca maximizar recompensas ao longo do tempo
- Pontos cruciais:
 - Dados de qualidade
 - Algoritmos eficientes
 - Poder computacional
 - Métodos de validação

Atividade 29: Apresentação dinâmica de Fundamentos de IA - "Conceitos sobre aprendizagem de máquina"

Qual tipo de aprendizado de máquina utiliza dados com rótulos durante o treinamento para classificar corretamente novos dados na fase de teste?

☒ Aprendizado Supervisionado

☐ Aprendizado Não Supervisionado

☐ Aprendizado por Reforço

☐ Aprendizado Semi-supervisionado

Sua pontuação: 10 de 40

Questão 1 de 4

Continuar >

Atividade 29: Apresentação dinâmica de Fundamentos de IA - "Conceitos sobre aprendizagem de máquina"

Qual das alternativas abaixo descreve corretamente o objetivo da regressão em aprendizado de máquina?

☒ Estimar valores contínuos com base em variáveis de entrada

☐ Identificar grupos de dados sem rótulos

☐ Prever categorias discretas em um conjunto de dados

☐ Prever a probabilidade de uma categoria binária

Sua pontuação: 20 de 40

Questão 2 de 4

Continuar >

Qual técnica de redução de dimensionalidade transforma os dados em variáveis não correlacionadas, chamadas de componentes principais, ordenadas pela quantidade de variação?

- ☐ k-Means
- ☐ Análise Discriminante Linear (LDA)
- ☒ Análise de Componentes Principais (PCA)
- ☐ Autoencoders



Sua pontuação: 30 de 40

Questão 3 de 4

Continuar >

Qual algoritmo de agrupamento assume que os dados são uma mistura de várias distribuições gaussianas?

- ☐ Análise de Componentes Principais (PCA)
- ☒ Gaussian Mixture Models (GMM)
- ☐ k-Means
- ☐ Hierarchical Clustering